

# Stochastik

Poisson-Verteilung / Parameterschätzung

Mirko Birbaumer

Hochschule Luzern Technik & Architektur

- 1 Poisson-Verteilung
- 2 Wahrscheinlichkeitsrechnung versus Statistik
- 3 Momenten- und Maximum-Likelihood-Methode

# Poisson-Verteilung: $X \sim \text{Pois}(\lambda)$ , $\lambda > 0$

- Bei Binomial( $n, \pi$ )-Verteilung nimmt  $X$  beschränkten Wertebereich an

$$W = \{0, 1, \dots, n\}$$

- Oft ist aber nicht von vornherein klar, wieviele Beobachtungen eintreten
- Beispiele:
  - Anzahl Anrufe in einem Callcenter pro Stunde
  - Anzahl Schadensmeldungen eines Versicherten pro Jahr
  - Anzahl Autounfälle pro Tag
  - Anzahl  $\alpha$ -Zerfälle pro Sekunden
- Jede Zahl möglich (zumindest theoretisch)
- D.h.  $n$  unbekannt  $\rightarrow$  Binomialverteilung nicht anwendbar

# Poisson-Verteilung: $X \sim \text{Pois}(\lambda)$ , $\lambda > 0$

- Für unbeschränkte **Zähl**daten: Poisson-Verteilung

## Poisson-Verteilung



Eine Zufallsvariable  $X$  mit Werten in  $\mathbb{N}_0 = \{0, 1, 2, \dots\}$  heisst Poisson( $\lambda$ )-verteilt, falls



$$P(X = x) = \exp(-\lambda) \frac{\lambda^x}{x!} \quad (x = 0, 1, 2, \dots),$$



wobei  $\lambda > 0$  ein Parameter der Verteilung ist.

Erwartungswert / Varianz / Standardabweichung:

$$E(X) = \lambda; \quad \text{Var}(X) = \lambda; \quad \sigma(X) = \sqrt{\lambda}$$

Poisson-Verteilung ( $\lambda = 0.3$ )

Poisson-Verteilung ( $\lambda = 2$ )

Poisson-Verteilung ( $\lambda = 6$ )

# Bedeutung von $\lambda$ in Poisson-Verteilung

- Für  $X \sim \text{Pois}(\lambda) : E(X) = \lambda$
- Bedeutung von  $\lambda$  : der zu erwartende Wert von  $X$
- Oft ist  $\lambda$  allerdings unbekannt und wir müssen ihn *schätzen*, siehe Kapitel Parameterschätzung



# Beispiel: Callcenter

- Callcenter: erfahrungsgemäss treffen durchschnittlich 350 Telefonanrufe in der Stunde ein
- Allerdings ist es möglich, dass manchmal gar kein Anruf kommt und in der nächsten Stunde 1000
- Die Anzahl der möglichen Anrufe ist, theoretisch, nach oben offen
- Anzahl Anrufe pro Stunde modelliert durch Zufallsvariable  $X$ , für die die Poissonverteilung angenommen werden kann

$$X \sim \text{Pois}(\lambda), \lambda = 350 \quad (E[X] = \lambda = 350)$$

# Beispiel: Callcenter

- Wie gross ist W'keit, dass innerhalb einer Stunde keine Anrufe eingehen?

$$P[X = 0] = e^{-350} \frac{350^0}{0!} = 9.929\,59 \times 10^{-153}$$

Dieses Ereignis ist also extrem unwahrscheinlich

- R-Befehl

**R-Befehl: dpois()**

```
> dpois(x=0,lambda=350)
[1] 9.92959e-153
```

- W'keit, dass genau 350 Anrufe eintreffen: (mit R: dpois())

$$P(X = 350) = 0.021$$

# Beispiel: Callcenter

- Viel grösser als die W'keit, dass genau 350 Anrufe eintreffen, ist W'keit, dass zwischen 340 und 360 eingehen:

$$P(340 \leq X \leq 360) = 0.425$$

- Somit treffen in 42.5 % aller Stunden zwischen 340 und 360 Anrufe ein

# Poissonverteilung als Binomialverteilung

- Betrachte  $X \sim \text{Binomial}(n, \pi)$  und  $Y \sim \text{Poisson}(\lambda)$

Falls  $n$  gross und  $\pi$  klein mit  $\lambda = n\pi$ , dann:

$$P(X = x) = \binom{n}{x} \pi^x (1 - \pi)^{n-x} \approx P(Y = x) = \exp(-\lambda) \frac{\lambda^x}{x!}$$

für  $x = 0, 1, \dots, n$

- Das heisst: für grosse  $n$  und kleine  $\pi$ :  
 $\text{Binomial}(n, \pi) \approx \text{Poisson}(\lambda)$  mit  $\lambda = n\pi$
- Mit anderen Worten: die Poisson-Verteilung kann interpretiert werden als Verteilung für *seltene Ereignisse bei vielen unabhängigen Versuchen*

# Poisson-Verteilung: Additionseigenschaft

- Ist  $X \sim \text{Pois}(\lambda_1)$ ,  $Y \sim \text{Pois}(\lambda_2)$ , unabhängig, dann ist

$$X + Y \sim \text{Pois}(\lambda_1 + \lambda_2)$$

- Die Anzahl Ausfälle eines Systems in einem Zeitintervall der Länge  $t$  kann z.B. als  $\text{Pois}(\lambda t)$  modelliert werden
- Beispiel: Callcenter erhält Telefonanrufe als ein Poisson-Prozess mit  $\lambda = 350$  pro Stunde
- Annahme: Die Anzahl eintreffender Anrufe pro Stunde sind von Stunde zu Stunde unabhängig
- Die Anzahl Anrufe in einem 24 Stunden Intervall folgt dann einer Poisson-Verteilung mit Parameter

$$\tilde{\lambda} = 24 \cdot \lambda = 8400$$

# Poisson-Verteilung: Radioaktiver Zerfall

- In Bezug auf Gesamtzahl Atome in einer radioaktiven Substanz: Alpha-Zerfall ist ein seltenes Ereignis, also  $\pi$  klein
- Anzahl Zerfälle ist nach oben nicht begrenzt (**unbeschränkte Zählraten**)
- Jeder Zerfall ist unabhängig vom vorhergehenden
- Jede Anzahl Zerfälle in 10 Sekunden hat gemäss der Poisson-Verteilung die Wahrscheinlichkeit:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

- Frage: Wie können wir  $\lambda$  schätzen?

# Wie stelle ich ein Wahrscheinlichkeitsmodell auf?

## Fragestellung (betreffend unsicherem Phänomen)

Bsp: Erwartete Anzahl Überschwemmungen in den nächsten 10 Jahren?

## Annahmen

Bsp: Jährliche W'keit sei  $p=0.1$ , Ereignisse in verschiedenen Jahren seien unabhängig.

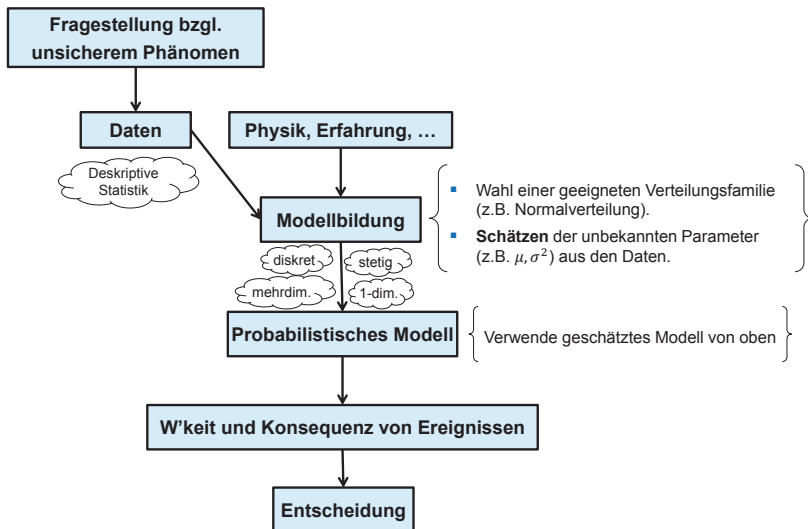
## Modell

Bsp: Modelliere Anzahl Überschwemmungen mit Binomialverteilung.

## Antwort (basierend auf Modell)

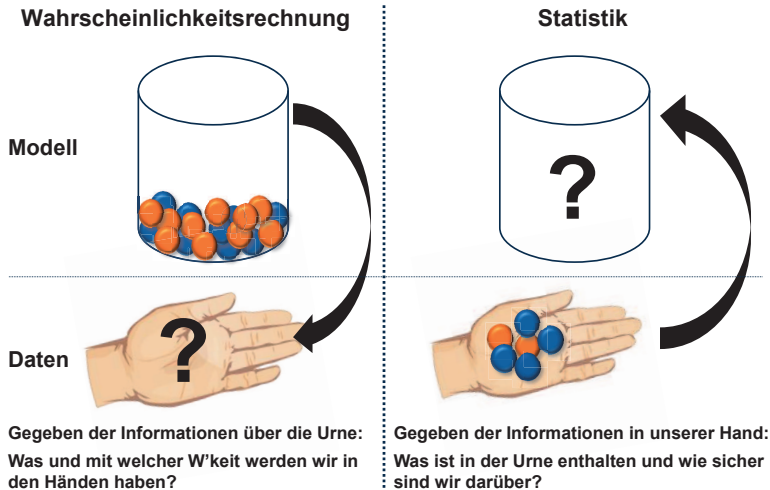
Bsp: Erwartete Anzahl, W'keit dass keine Überschwemmung, etc.

# Wahrscheinlichkeitsmodell beruhend auf Daten





# Wahrscheinlichkeitsrechnung vs. Statistik



# Schätzung bei Binomialverteilung und Poisson-Verteilung

- Problem:
  - Beim Alphazerfall ist der Parameter  $\lambda$  unbekannt
  - Beim Würfelwurf ist die Wurfw'keit  $\pi$ , um „Kopf“ zu werfen, unbekannt
- Wie kann man aus Beobachtung(en) die Parameter  $\lambda$  bzw.  $\pi$  annähern (schätzen)?
- Es gibt zwei verbreitete Methoden, um Parameter einer Wahrscheinlichkeitsverteilung zu schätzen:
  - die **Momentenmethode**
  - die **Maximum-Likelihood-Schätzermethode**

# Bemerkungen

- Um einen Schätzwert einer Grösse zu kennzeichnen, wird ein Hut ( $\hat{\phantom{x}}$ ) auf die Variable gesetzt
- Beispiele:
  - $\hat{\pi}$  ein Schätzwert des Parameters  $\pi$
  - $\hat{E}(X)$  ist ein Schätzwert des wahren Erwartungswertes  $E(X)$
  - $\hat{y}$  ist ein Schätzwert der Variable  $y$
- Begriff „Schätzung“ im statistischen Sinne:
  - Wir *berechnen* diesen Wert aufgrund von unvollständigen Informationen
  - Dieser berechnete Wert ist dann eben die Schätzung einer Grösse, die wir nicht kennen

# Momentenmethode bei Binomialverteilung: Beispiel

- Münzenwurf: in 50 Würfeln wird 35 mal „Kopf“ geworfen
- Unbekannt: Münze fair oder nicht
- Parameter  $\pi$  ist also unbekannt
- Welcher Wert für  $\pi$  ist aus der Beobachtung anzunehmen?
- Vermutung:

$$\hat{\pi} = \frac{35}{50}$$

# Momentenmethode bei Binomialverteilung

- Betrachten folgende Situation: Gegeben ist eine Beobachtung  $x$ , welche als Realisierung von  $X \sim \text{Binomial}(n, \pi)$  aufgefasst wird
- Möchten Schlüsse über den *unbekannten* Parameter  $\pi$  ziehen
- Für Binomialverteilung  $\text{Binomial}(n, \pi)$  ist der Erwartungswert  $E(X)$ :

$$E(X) = n\pi$$

- Für Parameter  $\pi$  gilt dann

$$\pi = \frac{E(X)}{n}$$

# Momentenmethode bei Binomialverteilung

- Wert  $n$  (Anzahl unabhängiger Versuche) ist **bekannt**;  $E(X)$  ist **unbekannt**
- Erste Schätzung: Erwartungswert  $E(X)$  wird durch Beobachtung  $x$  geschätzt:

$$\hat{E}(X) = x = \text{beobachtete Anzahl Gewinne}$$

## Momentenmethode

Somit ergibt sich aufgrund der **Momentenmethode** die relative Häufigkeit

$$\hat{\pi} = \frac{x}{n}$$

als Schätzung der Erfolgswahrscheinlichkeit.

# Beispiel: Münzwurf

- Münze: Ist sie fair ist oder ergibt es systematisch eher „Kopf“?
- Beobachtung: Münze 100-mal geworfen und 58 mal „Kopf“ erhalten
- Zufallsvariable  $X = \text{Anzahl „Kopf“}(K)$  bei 100 Würf
- Vernünftiges Modell

$$X \sim \text{Binomial}(100, \pi)$$

- Beobachtet (realisiert) wurde  $x = 58$
- W'keit, dass die Münze bei einem Wurf Kopf zeigt, ist gemäss der Momentenmethode also

$$P(K) = \hat{\pi} = \frac{58}{100} = 0.58$$

# Schätzung aus mehreren Beobachtungen: Beispiel

- Werfen Münze und machen dabei zwei Versuche:
  - Im 1. Versuch werfen wir 50 mal und erreichen 30 mal  $K$
  - Im 2. Versuch sind es 115 mal  $K$  auf 160 Würfe
- 1. Versuch:  $X_1 \sim \text{Bin}(50, \pi)$ ;    2. Versuch:  $X_2 \sim \text{Bin}(160, \pi)$
- Schätzungen

$$\hat{\pi}_1 = \frac{30}{50} = 0.6 \quad \text{und} \quad \hat{\pi}_2 = \frac{115}{160} = 0.72$$

- Können beide Versuche zusammen als grossen Versuch mit 210 Würfeln und 145 Erfolgen  $K$  ansehen  $\rightarrow X \sim \text{Bin}(210, \pi)$
- Dann ist der geschätzte Parameter

$$\hat{\pi} = \frac{30 + 115}{50 + 160} = \frac{145}{210} = 0.69$$



# Maximum-Likelihood bei Binomialverteilung

- Andere, weit verbreitete Methode zur Parameterschätzung:  
*Maximum-Likelihood-Methode*
- Annahme: Anzahl „Kopf“ bei  $n$  Münzwürfen verteilt wie:

$$X \sim \text{Binomial}(n, \pi)$$

- Hier:  $n = 100$  und die Zufallsvariable  $X$  hat den Wert 58 angenommen
- Aufgabe: einen Wert für  $\pi$  zu finden, der möglichst gut zu unserer Beobachtung passt
- Welches Kriterium könnte man verwenden, um zu zeigen, dass ein Wert  $\pi_1$  besser zu der Beobachtung passt als  $\pi_2$ ?

# Maximum-Likelihood bei Binomialverteilung

- Möglichkeit: Berechnen die W'keit, genau 58 mal Kopf bei 100 Münzwürfen zu erzielen
- Verwenden dabei z.B.  $\pi_1 = 0.5$  und  $\pi_2 = 0.6$
- Zugehörige W'keiten:

$$P_{0.5}(X = 58) = 0.0223 \quad \text{und} \quad P_{0.6}(X = 58) = 0.074$$

- Schätzung von  $\pi$  : wählen das  $\pi$  aus, das zur grösseren W'keit für 58 mal Kopf führt:

$$\hat{\pi} = 0.6$$

# Maximum-Likelihood bei Binomialverteilung

- Um den *wahrscheinlichsten* Wert für  $\pi$  zu erhalten, müsste man natürlich nicht nur zwei Werte von  $\pi$  vergleichen, sondern alle, die denkbar sind
- Ziel:  $\pi$  so wählen, dass Ausdruck maximal wird

$$P[X = 58] = \binom{100}{58} \pi^{58} (1 - \pi)^{42}$$

- Bekannte Problemstellung:
  - Ausdruck nach  $\pi$  ableiten
  - Ableitung nach  $\pi$  gleich null setzen
  - Gleichung nach  $\pi$  auflösen

$$\frac{d}{d\pi} \left( \binom{100}{58} \pi^{58} (1 - \pi)^{42} \right) = 0 \quad \rightarrow \quad \pi = \frac{58}{100}$$

# Maximum-Likelihood bei Binomialverteilung

- Im allgemeinen:  $\pi$  so wählen, dass der Ausdruck maximal wird:

$$P[X = x] = \binom{n}{x} \pi^x (1 - \pi)^{n-x}$$

- Dann muss gelten (mit  $n$  und  $x$  als Parameter)

$$\frac{d}{d\pi} \left( \binom{n}{x} \pi^x (1 - \pi)^{n-x} \right) = 0 \quad \rightarrow \quad \pi = \frac{x}{n}$$

- Resultat für die Schätzung  $\hat{\pi}$

$$\hat{\pi} = \frac{x}{n}$$

- In unserem Beispiel mit  $x = 58$  und  $n = 100$

$$\hat{\pi} = \frac{58}{100} = 0.58$$

# Bemerkungen zur Maximum-Likelihood-Methode

- In diesem Beispiel ist das Ergebnis identisch mit dem Ergebnis aus der Momentenmethode: im allgemeinen ist das aber nicht der Fall!
- Obige Methode wird **Maximum-Likelihood-Methode**
- Sie ist die mit Abstand gebräuchlichste Methode, um Parameter zu schätzen und oft der Momentenmethode überlegen
- Die zu maximierende Funktion heisst **Likelihood-Funktion**  $L(\pi)$  (das  $\pi$  deutet an, dass dann nach  $\pi$  abgeleitet wird):

$$L(\pi) = \binom{n}{x} \pi^x (1 - \pi)^{n-x}$$

# Parameterschätzung mit R

## R-Befehl: `binom.test()`

```
> binom.test(x=58, n=100, p=0.5, alternative= "two.sided",  
conf.level=0.95)
```

Exact binomial test

data: 58 and 100

number of successes = 58, number of trials = 100, p-value  
= 0.1332

alternative hypothesis: true probability of success is not  
equal to 0.5

95 percent confidence interval:

0.4771192 0.6780145

sample estimates:

probability of success

0.58

# Schätzung aufgrund von mehreren Beobachtungen

- Werfen Münze und machen dabei zwei Versuche:
  - Im 1. Versuch werfen wir 50 mal und erreichen 30 mal  $K$
  - Im 2. Versuch sind es 115 mal  $K$  auf 160 Würfe
- 1. Versuch:  $X_1 \sim \text{Bin}(50, \pi)$ ; 2. Versuch:  $X_2 \sim \text{Bin}(160, \pi)$
- Wichtig: Parameter  $\pi$  bei beiden gleich
- Schätzung: Maximum-Likelihood-Methode
- Gesucht: W'keit

$$P[(X_1 = 30) \cap (X_2 = 115)]$$

# Schätzung aufgrund von mehreren Beobachtungen

- Annahme: Beide Versuche stochastisch unabhängig

$$\begin{aligned} P[(X_1 = 30) \cap (X_2 = 115)] &= P[X_1 = 30] \cdot P[X_2 = 115] \\ &= \binom{50}{30} \pi^{30} (1 - \pi)^{20} \cdot \binom{160}{115} \pi^{115} (1 - \pi)^{45} \end{aligned}$$

- Ausdruck hängt von  $\pi$  ab: dies ist die **Likelihood-Funktion**:

$$L(\pi) = \binom{50}{30} \pi^{30} (1 - \pi)^{20} \cdot \binom{160}{115} \pi^{115} (1 - \pi)^{45}$$

- Vorgehen:
  - Funktion nach  $\pi$  ableiten
  - Ableitung nach  $\pi$  gleich null setzen
  - Gleichung nach  $\pi$  auflösen

- Resultat:  $\hat{\pi} = \frac{145}{210}$



# Schätzung aufgrund von mehreren Beobachtungen

- Im allgemeinen Fall für  $X_1 = x_1$  und  $X_2 = x_2$  mit  $n_1$  bzw.  $n_2$  Versuchen
- Mit Maximum-Likelihood-Methode

$$\hat{\pi} = \frac{x_1 + x_2}{n_1 + n_2}$$

- Dies ist dasselbe Resultat wie bei der Momentenmethode, was für andere Verteilungen aber nicht der Fall sein muss.

# Momentenmethode bei Poisson-Verteilung

- Daten  $x_1, x_2, \dots, x_m$  als Realisierungen von

$$X_1, \dots, X_m \sim \text{Poisson}(\lambda)$$

- Wie lässt sich  $\lambda$  aus den Daten schätzen?

# Beispiel: Kanzerogene Fasern

- Hersteller für Isolationsmaterialien misst die Anzahl krebserregende Fasern pro  $\text{mm}^2$  in 5 Proben

- Die gemessenen Werte  $x_1, \dots, x_5$  seien:

$$4, 1, 2, 3, 6$$

- Modell: Anzahl krebserregender Fasern mit einer Poisson-Verteilung, da die mögliche Anzahl Fasern nicht nach oben begrenzt ist

- Annahme: Beobachtungen  $x_1, \dots, x_5$  Realisierungen von

$$X_1, \dots, X_5 \sim \text{Poisson}(\lambda)$$

- Wie sollen wir  $\lambda$  wählen? Was ist unsere Schätzung  $\hat{\lambda}$  basierend auf den beobachteten Daten?

# Beispiel: Kanzerogene Fasern

- Erwartungswert der Poisson-Verteilung:

$$E(X) = \lambda$$

- Schätzen nun den Erwartungswert mit dem empirischen Mittelwert

$$\hat{E}(X) = \bar{x} = \frac{4 + 1 + 2 + 3 + 6}{5} = 3.2$$

- Schätzung für den Parameterwert  $\lambda$  der Poisson-Verteilung

$$\hat{\lambda} = \bar{x} = 3.2$$

# Momentenmethode für beliebige Wahrscheinlichkeitsverteilungen

Wir fassen unsere Daten  $x_1, x_2, \dots, x_n$  als Realisierungen einer Zufallsvariablen  $X$  auf.

Falls die Zufallsvariable  $X$  einer bekannten Wahrscheinlichkeitsverteilung mit unbekanntem Parameter  $\vartheta$  folgt, dann berechnet man zuerst den Erwartungswert  $E(X)$  und löst die Gleichung nach dem unbekannten Parameter  $\vartheta$  der Wahrscheinlichkeitsverteilung auf.

Dann ersetzt man den Erwartungswert durch dessen empirisches Gegenstück, den empirischen Mittelwert, und man erhält einen **Momentenschätzer** für den unbekannten Parameter  $\vartheta$ .

# Maximum-Likelihood bei Poisson-Verteilung: Beispiel

- Hersteller für Isolationsmaterialien misst die Anzahl krebserregende Fasern pro  $\text{mm}^2$  in 5 Proben

- Die gemessenen Werte  $x_1, \dots, x_5$  seien:

$$4, 1, 2, 3, 6$$

- Modell: Anzahl krebserregender Fasern mit einer Poisson-Verteilung, da die mögliche Anzahl Fasern nicht nach oben begrenzt ist

- Annahme: Beobachtungen  $x_1, \dots, x_5$  Realisierungen von

$$X_1, \dots, X_5 \sim \text{Poisson}(\lambda)$$

- Wie sollen wir  $\lambda$  wählen? Was ist unsere Schätzung  $\hat{\lambda}$  basierend auf den beobachteten Daten?


# Maximum-Likelihood bei Poisson-Verteilung: Kanzerogene Fasern

- Für ein gegebenes  $\lambda$  ist die *Wahrscheinlichkeit*, genau die gemessenen Werte  $x_1 = 4, \dots, x_5 = 6$  zu beobachten:

$$P[(X_1 = 4) \cap (X_2 = 1) \cap \dots \cap (X_5 = 6)]$$

- Annahme: Messungen sind stochastisch unabhängig voneinander
- Dann gilt für die **Likelihood-Funktion**  $L$ :

$$\begin{aligned} L(\lambda) &= P(X_1 = 4) \cdot P(X_2 = 1) \cdot P(X_3 = 2) \cdot P(X_4 = 3) \cdot P(X_5 = 6) \\ &= e^{-\lambda} \frac{\lambda^4}{4!} \cdot e^{-\lambda} \frac{\lambda^1}{1!} \cdot e^{-\lambda} \frac{\lambda^2}{2!} \cdot e^{-\lambda} \frac{\lambda^3}{3!} \cdot e^{-\lambda} \frac{\lambda^6}{6!} \end{aligned}$$

Abbildung von  $L(\lambda)$ 



# Maximum-Likelihood bei Poisson-Verteilung: Beispiel

- Für jedes  $\lambda$  kann man den Wert  $L(\lambda)$  berechnen
- Suchen nun das  $\lambda$ , welches die beobachteten Daten  $x_1 = 4, \dots, x_5 = 6$  möglichst plausibel erscheinen lässt
- Suchen also das  $\lambda$ , welches  $L(\lambda)$  *maximiert*, also grösstmöglich macht
- Graphisch:  $L(\lambda)$  ein Maximum an der Stelle  $\hat{\lambda} = 3.2$
- Schätzen wir also  $\lambda$  mit 3.2, also  $\hat{\lambda} = 3.2$
- Die beobachteten Daten passen nun am besten mit dem Modell  $X_i \sim \text{Pois}(\lambda)$


# Maximum-Likelihood bei Poisson-Verteilung: Berechnung von $\hat{\lambda}$

- Berechnung von  $\hat{\lambda}$ : Likelihood-Funktion nach  $\lambda$  ableiten, gleich null setzen und nach  $\lambda$  auflösen
- Nachteil: rechnerisch ist dies sehr aufwändig
- Rechnerisch ist es vorteilhafter, mit der **log-Likelihood-Funktion** zu arbeiten

$$l(\lambda) = \log(L(\lambda))$$

- Maximum der Funktion  $l(\lambda)$  liegt nach wie vor an der Stelle  $\hat{\lambda} = 3.2$

# Log-Likelihood Funktion für Datensatz kanzerogener Fasern



# Maximum-Likelihood bei Poisson-Verteilung: Berechnung von $\hat{\lambda}$

- **log-Likelihood-Funktion:**

$$l(\lambda) = \log \left( \prod_{i=1}^n e^{-\lambda} \frac{\lambda^{x_i}}{x_i!} \right) = \sum_{i=1}^n \log \left( e^{-\lambda} \frac{\lambda^{x_i}}{x_i!} \right)$$

- Leitet man  $l(\lambda)$  nach  $\lambda$  ab und setzt  $l'(\lambda) = 0$ , so erhält man die Gleichung

$$\frac{1}{\lambda} \sum_{i=1}^n x_i - n = 0 .$$

- Maximum-Likelihood Schätzer :

$$\hat{\lambda} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

# Maximum-Likelihood Schätzer

## Maximum-Likelihood Schätzer

Es liegen  $m$  Beobachtungen  $x_1, x_2, \dots, x_m$  vor. Sind die Datenpunkte  $x_i$  Realisierungen der unabhängigen Zufallsvariablen  $X_i \sim \text{Binomial}(n_i, \pi)$ , so ergibt der Maximum-Likelihood-Schätzer:

$$\hat{\pi} = \frac{x_1 + x_2 + \dots + x_m}{n_1 + n_2 + \dots + n_m}$$

Sind die Datenpunkte  $x_i$  Realisierungen der unabhängigen Zufallsvariablen  $X_i \sim \text{Poisson}(\lambda)$ , so ergibt der Maximum-Likelihood-Schätzer:

$$\hat{\lambda} = \bar{x} = \frac{x_1 + x_2 + \dots + x_m}{m}$$

# Zusammenfassung Parameterschätzer

- Für unsere beobachteten Daten nehmen wir ein **Modell** an (z.B. Binomialverteilung)
- Das Modell enthält unbekannte Parameter (z.B.  $\pi$ )
- Basierend auf den beobachteten Daten versuchen wir, die Parameter zu schätzen (z.B. mit Momentenmethode, Maximum-Likelihood Methode).
- **Das heisst, dass wir basierend auf den beobachteten Daten versuchen, Rückschlüsse über den datengenerierenden Mechanismus zu ziehen!**