# **Stochastik**

# Musterlösungen zu Serie 1

## Lösung 1.1

a) Die Datei child.txt lesen wir mit folgendem Befehl ein

```
data <- read.table(file = "./Daten/child.txt",
    header = TRUE, sep = ",")</pre>
```

Die Dimension ermitteln wir dann mit

```
dim(data)
## [1] 30 21
```

Der Datensatz enthält also 30 Zeilen und 21 Spalten.

b) Eine Zusammenfassung lässt sich mit R folgendermassen erhalten:

```
summary (data)
##
   Average.disposable.income Children.in.poor.homes
                     Min. : 2.740
## Min. : 3.839
## 1st Qu.:16.618
                          1st Qu.: 8.901
## Median :21.107
                           Median :11.659
## Mean :18.848
                          Mean :12.372
##
  3rd Qu.:22.643
                          3rd Qu.:16.092
##
  Max. :34.242
                          Max. :24.590
##
## Educational.Deprivation Overcrowding
## Min. : 0.400
                        Min. :10.33
## 1st Qu.: 1.000
                         1st Qu.:17.06
## Median : 1.500
                        Median :21.57
## Mean : 2.673
                        Mean :31.95
   3rd Qu.: 2.200
                         3rd Qu.:44.39
##
   Max. :13.700
##
                         Max. :73.96
##
                         NA's
                                : 4
##
  Poor.environmental.conditions
## Min. :10.50
##
  1st Qu.:20.15
## Median :25.49
## Mean :25.22
## 3rd Qu.:30.24
## Max. :38.71
```

```
## NA's :6
   Average.mean.literacy.score Literacy.inequality
                          Min. :1.475
##
  Min. :408.7
##
   1st Qu.:482.8
                          1st Qu.:1.623
   Median:501.3
                          Median :1.683
##
##
   Mean :496.3
                          Mean :1.665
##
   3rd Qu.:512.8
                           3rd Qu.:1.719
##
   Max. :552.7
                           Max. :1.756
##
   Youth.NEET.rate Low.birth.weight Infant.mortality
##
##
   Min. : 1.700 Min. : 3.900 Min. : 2.300
##
   1st Qu.: 4.550 1st Qu.: 5.150 1st Qu.: 3.525
##
   Median: 6.200 Median: 6.750 Median: 4.200
##
   Mean : 7.378 Mean : 6.643 Mean : 5.447
   3rd Qu.: 8.400 3rd Qu.: 7.500 3rd Qu.: 5.250
##
##
   Max. :37.700 Max. :11.300 Max. :23.600
##
   NA's
         : 3
##
   Breastfeeding.rates Vaccination.rates..pertussis.
##
   Min. :41.00 Min. :78.00
   1st Qu.:79.00
                    1st Qu.:91.00
##
##
   Median :91.00
                   Median :95.80
##
   Mean
         :86.03
                    Mean
                          :93.78
##
   3rd Ou.:96.00
                    3rd Ou.:97.80
   Max. :99.00
                    Max. :99.80
##
##
   NA's
         :1
                   NA's
                          : 1
##
   Vaccination.rates.measles. Physical.activity
##
  Min. :74.00
                         Min. :13.10
##
   1st Ou.:88.00
                          1st Qu.:15.80
## Median :94.00
                         Median :19.30
##
   Mean :91.52
                         Mean :20.13
   3rd Qu.:96.30
##
                          3rd Qu.:21.80
##
   Max. :99.80
                         Max. :42.10
##
   NA's
         : 1
                         NA's :4
##
   Mortality.rates Suicide.rates
                                 Smoking
   Min. :14.84 Min. : 1.263 Min. : 8.10
##
##
   ##
   Median :23.15 Median : 6.785 Median :16.60
   Mean :24.60 Mean : 6.856 Mean :16.51
##
   3rd Qu.:25.75 3rd Qu.: 8.864 3rd Qu.:19.50
##
   Max. :50.23 Max. :15.950 Max. :27.10
##
##
   NA's
        :1
                NA's :1
                              NA's :6
##
   Drunkenness Teenage.births Bullying
## Min. :10.00 Min. : 3.70 Min. : 4.200
## 1st Qu.:11.35 1st Qu.: 7.05 1st Qu.: 7.975
```

c) Wir wollen die Zeilennamen unseres Datensatzes ermitteln

```
rownames (data)
   [1] "Australia"
                          "Austria"
##
## [3] "Belgium"
                          "Canada"
## [5] "Czech Republic" "Denmark"
## [7] "Finland"
                          "France"
## [9] "Germany"
                          "Greece"
                          "Iceland"
## [11] "Hungary"
## [13] "Ireland"
                          "Italy\t"
                          "Korea\t"
## [15] "Japan\t"
## [17] "Luxembourg"
                          "Mexico"
## [19] "Netherlands"
                          "New Zealand"
## [21] "Norway"
                          "Poland"
## [23] "Portugal"
                          "Slovak Republic"
## [25] "Spain\t"
                          "Sweden"
## [27] "Switzerland"
                          "Turkey"
                          "United States\t"
## [29] "United Kingdom"
```

Die Niederlande ist also im Datensatz enthalten, China hingegen nicht.

d) Die Werte für Bullying der Länder in der fünften bis zehnten Zeile lauten:

```
data[5:10, "Bullying"]
## [1] 5.5 8.0 8.0 13.6 13.9 22.0

rownames(data)[5:10]
## [1] "Czech Republic" "Denmark"
## [3] "Finland" "France"
```

```
## [5] "Germany" "Greece"
```

#### e) Die Variablen heissen

```
colnames (data)
    [1] "Average.disposable.income"
##
    [2] "Children.in.poor.homes"
    [3] "Educational.Deprivation"
##
##
    [4] "Overcrowding"
    [5] "Poor.environmental.conditions"
##
    [6] "Average.mean.literacy.score"
##
    [7] "Literacy.inequality"
##
    [8] "Youth.NEET.rate"
##
##
   [9] "Low.birth.weight"
## [10] "Infant.mortality"
## [11] "Breastfeeding.rates"
## [12] "Vaccination.rates..pertussis."
## [13] "Vaccination.rates.measles."
## [14] "Physical.activity"
## [15] "Mortality.rates"
## [16] "Suicide.rates"
## [17] "Smoking"
## [18] "Drunkenness"
## [19] "Teenage.births"
## [20] "Bullying"
## [21] "Liking.school"
```

Um zu ermitteln, in welchen 5 Ländern die meisten Jugendlichen mindestens zweimal betrunken sind, benützen wir

```
order(...)
```

um die Zeilen in aufsteigender Reihenfolge zu ermitteln

```
order(data[, "Drunkenness"], na.last = F) [26:30]
## [1] 4 22 29 7 6
```

Dabei stellt das Argument na.last=F die Zeilen mit den nicht vorhandenen Datenpunkten am Anfang des geordneten Datenvektors. Die Ländernamen lauten dann

```
rownames (data[order(data[, "Drunkenness"], na.last = F) [26:30],
])
```

```
## [1] "Canada" "Poland"
## [3] "United Kingdom" "Finland"
## [5] "Denmark"
```

In Dänemark sind die meisten Jugendlichen mindestens zweimal betrunken, nämlich

```
data["Denmark", "Drunkenness"]
## [1] 24.8
```

Prozent der dänischen Jugendlichen.

f) Die Zeile, in der der Wert mit der kleinsten Säuglingssterblichkeit steht, lautet

```
which.min(data[, "Mortality.rates"])
## [1] 17
```

Das betreffende Land ist

g) Der Mittelwert der Anzahl an Jugendlichen, die sich regelmässig bewegen, lautet

```
mean(data[, "Physical.activity"], na.rm = T)
## [1] 20.13462
```

Also in folgenden Ländern ist die Anzahl an Jugendlichen, die sich regelmässig bewegen, kleiner als im OECD Durchschnitt

```
mean.physical.activity <- mean(data[, "Physical.activity"],
    na.rm = T)
which(data[, "Physical.activity"] < mean.physical.activity)
## [1] 2 3 8 9 10 11 14 17 18 21 22 23 26 27 28
## [16] 29
rownames(data[which(data[, "Physical.activity"] < mean.physical.activity), ])
## [1] "Austria" "Belgium"
## [3] "France" "Germany"</pre>
```

```
## [5] "Greece"
                            "Hungary"
                            "Luxembourg"
  ## [7] "Italy\t"
  ## [9] "Mexico"
                            "Norway"
                            "Portugal"
  ## [11] "Poland"
  ## [13] "Sweden"
                            "Switzerland"
  ## [15] "Turkey"
                            "United Kingdom"
h) order(data[, "Average.disposable.income"])
       [1] 23 28 18 24 22 11 5 25 14 10 20 8
                                                      1
  ## [16] 3 16 7 2 12 13 15 29 6 27 19 4 21 30 17
  write.table(data[order(data[, "Average.disposable.income"]),
      ], file = "income_ordered.txt", col.names = TRUE,
      row.names = TRUE)
```

#### Wir können überprüfen, ob die Datei abgespeichert wurde

```
data <- read.table(file = "income_ordered.txt", header = TRUE)</pre>
rownames (data)
##
   [1] "Portugal"
                           "Turkey"
## [3] "Mexico"
                           "Slovak Republic"
##
   [5] "Poland"
                           "Hungary"
## [7] "Czech Republic" "Spain\t"
## [9] "Italy\t"
                           "Greece"
## [11] "New Zealand"
                          "France"
## [13] "Germany"
                           "Sweden"
## [15] "Australia"
                           "Belgium"
## [17] "Korea\t"
                           "Finland"
## [19] "Austria"
                           "Iceland"
## [21] "Ireland"
                           "Japan\t"
## [23] "United Kingdom" "Denmark"
## [25] "Switzerland"
                           "Netherlands"
## [27] "Canada"
                           "Norway"
## [29] "United States\t" "Luxembourg"
```

## Lösung 1.2

- a) Siehe Aufgabenstellung.
- b) Um die Daten in Tabellenform zu sehen, tippt man den Namen des Objektes ein

```
d.fuel
       X weight mpg
                        type
## 1
       1
            2560
                   33
                        Small
## 2
       2
            2345
                   33
                        Small
## 3
            1845
       3
                  37
                        Small
## 4
       4
            2260
                  32
                        Small
## 5
       5
            2440
                  32
                        Small
## 6
            2285
                  26
                        Small
       6
## 7
       7
            2275
                  33
                        Small
## 8
                        Small
       8
            2350
                  28
## 9
       9
            2295
                  25
                        Small
## 10 10
            1900
                  34
                        Small
## 11 11
            2390
                  29
                        Small
## 12 12
            2075
                  35
                        Small
## 13 13
            2330
                  26
                       Small
## 14 14
            3320
                  20
                       Sporty
## 15 15
            2885
                   27
                       Sporty
## 16 16
            3310
                  19
                       Sporty
## 17 17
            2695
                       Sporty
                   30
## 18 18
            2170
                   33
                       Sporty
## 19 19
            2710
                  27
                       Sporty
## 20 20
            2775
                   24
                       Sporty
## 21 21
            2840
                  26
                       Sporty
## 22 22
            2485
                  28
                       Sporty
## 23 23
            2670
                  27 Compact
## 24 24
            2640
                  23 Compact
## 25 25
            2655
                  26 Compact
## 26 26
            3065
                  25 Compact
## 27 27
            2750
                  24 Compact
## 28 28
            2920
                   26 Compact
## 29 29
            2780
                  24 Compact
## 30 30
            2745
                  25 Compact
## 31 31
            3110
                  21 Compact
## 32 32
            2920
                   21 Compact
## 33 33
            2645
                  23 Compact
## 34 34
            2575
                   24 Compact
## 35 35
            2935
                   23 Compact
## 36 36
            2920
                  27 Compact
                   23 Compact
## 37 37
            2985
## 38 38
           3265
                  20 Medium
```

```
## 39 39
           2880 21
                     Medium
## 40 40
           2975
                 22
                     Medium
## 41 41
           3450
                 22
                     Medium
## 42 42
           3145
                 22
                     Medium
## 43 43
           3190
                 22
                    Medium
## 44 44
           3610
                     Medium
                 23
## 45 45
           2885
                 23
                     Medium
## 46 46
                 21 Medium
           3480
## 47 47
           3200
                     Medium
                 22
## 48 48
           2765
                 21
                     Medium
## 49 49
                 21
           3220
                     Medium
## 50 50
           3480
                 23
                     Medium
## 51 51
           3325
                 23
                     Large
## 52 52
           3855
                 18
                      Large
## 53 53
           3850
                 20
                      Large
## 54 54
           3195
                 18
                         Van
## 55 55
           3735
                 18
                         Van
## 56 56
           3665
                 18
                         Van
## 57 57
           3735
                 19
                        Van
## 58 58
           3415
                 20
                        Van
## 59 59
           3185
                 20
                         Van
## 60 60 3690 19
                        Van
```

## c) Auswählen der fünften Beobachtung:

```
d.fuel[5, ]
## X weight mpg type
## 5 5 2440 32 Small
```

### d) Auswählen der 1. bis 5. Beobachtung:

```
d.fuel[1:5, ]
     X weight mpg type
##
## 1 1
         2560
               33 Small
## 2 2
         2345
               33 Small
## 3 3
         1845
               37 Small
## 4 4
         2260
               32 Small
## 5 5
       2440 32 Small
```

Alternativ kann man sich eine Übersicht verschaffen mit Hilfe der R-Funktion head (...)

```
head(d.fuel)

## X weight mpg type
## 1 1  2560  33  Small
## 2 2  2345  33  Small
## 3 3  1845  37  Small
## 4 4  2260  32  Small
## 5 5  2440  32  Small
## 6 6  2285  26  Small
```

e) Auswählen der 1. bis 3. und 57. bis 60. Beobachtung:

```
d.fuel[c(1:3, 57:60), ]
##
      X weight mpg type
                33 Small
## 1
       1
           2560
## 2
      2
          2345
                33 Small
                37 Small
## 3
     3
          1845
## 57 57
          3735
                19
                     Van
## 58 58
          3415
                20
                     Van
## 59 59
          3185
                20
                     Van
## 60 60 3690 19 Van
```

f) Die Werte der Reichweiten stehen in der dritten Spalte, die mpg heisst. Zur Berechnung des Mittelwertes gibt es verschiedene Möglichkeiten, welche sich in der Art der Datenselektion unterscheiden:

```
mean (d.fuel[, 3])
## [1] 24.58333

mean (d.fuel[, "mpg"])
## [1] 24.58333

mean (d.fuel$mpg)
## [1] 24.58333
```

g) Auch hier gibt es wieder verschiedene Möglichkeiten. Eine davon ist:

```
mean(d.fuel[7:22, "mpg"])
## [1] 27.75
```

h) Umrechnung der Miles Per Gallon in Kilometer pro Liter und der Pounds in Kilogramm:

```
t.kml <- d.fuel[, "mpg"] * 1.6093/3.789
t.kg <- d.fuel[, "weight"] * 0.45359
```

## Lösung 1.3

```
x <- c(2.1, 2.4, 2.8, 3.1, 4.2, 4.9, 5.1, 6, 6.4, 7.3, 10.8, 12.5, 13, 13.7, 14.8, 17.6, 19.6, 23, 25, 35.2, 39.6)
```

```
a) \sum x_i = \sum x_i^2 = 
sum (x)

## [1] 269.1

## [1] 5729.27
```

b) Mittelwert:  $\frac{1}{n} \sum x_i =$ 

```
n <- length(x)
mean.x <- 1/n * sum(x)
mean.x
## [1] 12.81429</pre>
```

### Standardabweichung:

```
var.x <- 1/(n - 1) * sum((x - mean.x)^2)
var.x
## [1] 114.0473</pre>
```

```
sqrt (var.x)
## [1] 10.67929
```

#### c) Median:

```
x.sorted <- sort(x)
0.5 * length(x)
## [1] 10.5</pre>
```

```
k <- round(0.5 * length(x) + 0.5)
k
## [1] 11
x.sorted[k]
## [1] 10.8</pre>
```

d) Das 25 % berechnet sich zu

```
0.25 * length(x)
## [1] 5.25

k <- round(0.25 * length(x) + 0.5)
k
## [1] 6

x.sorted[k]
## [1] 4.9</pre>
```

### und das 75 % Quantil ergibt

```
0.75 * length(x)
## [1] 15.75

k <- round(0.75 * length(x) + 0.5)
k
## [1] 16
x.sorted[k]
## [1] 17.6</pre>
```

e)

```
mean(x)
## [1] 12.81429
sd(x)
## [1] 10.67929
median(x)
## [1] 10.8
quantile(x, 0.75)
## 75%
## 17.6
```

f) Wir stellen aufgrund unseres Beispieldatensatzes für den arithmetischen Mit-

telwert und die Standardabweichung fest, dass

```
z <- (x - mean(x))/sd(x)
mean(z)

## [1] -2.614476e-17

sd(z)

## [1] 1</pre>
```

Im Allgemeinen ergibt sich für den arithmetischen Mittelwert von  $z_i$ 

$$\frac{1}{n} \sum_{i=1}^{n} z_i = \frac{1}{n} \sum_{i=1}^{n} \frac{x_i - \bar{x}}{s_x}$$

$$= \frac{1}{n \cdot s_x} \sum_{i=1}^{n} (x_i - \bar{x})$$

$$= \frac{1}{n \cdot s_x} \sum_{i=1}^{n} \left( \frac{n}{n} \cdot x_i - \bar{x} \right)$$

$$= \frac{1}{n \cdot s_x} \left( \frac{n}{n} \cdot \sum_{i=1}^{n} x_i - \sum_{i=1}^{n} \bar{x} \right)$$

$$= \frac{1}{n \cdot s_x} (n\bar{x} - n\bar{x})$$

$$= 0.$$

Für die Varianz von  $z_i$  erhalten wir

$$\frac{1}{n-1} \sum_{i=1}^{n} (z_i - \bar{z})^2 = \frac{1}{n-1} \sum_{i=1}^{n} (z_i - 0)^2$$

$$= \frac{1}{(n-1)} \sum_{i=1}^{n} \frac{x_i - \bar{x}^2}{s_x^2}$$

$$= \frac{1}{s_x^2} \frac{1}{(n-1)} \sum_{i=1}^{n} (x_i - \bar{x})^2$$

$$= \frac{1}{s_x^2} s_x^2$$

$$= 1.$$